



دانشکده علوم ریاضی

پروژه نهایی دوره کارشناسی

عنوان

خلاصه سازی متن مقالات علمی

نگارش

حنانه اسفندیار

علی رضا عباس زاده

استاد راهنما

دکتر مجتبی روحانی

شهریور ماه ۱۴۰۳

چکیده

این مطالعه به بررسی و توسعه روش‌های خلاصه‌سازی متن با تمرکز بر مقالات علمی می‌پردازد و از مدل‌های ترانسفورمر به‌عنوان ابزار اصلی در این فرآیند استفاده می‌کند. با توجه به حجم بالای اطلاعات علمی و نیاز به استخراج سریع و مؤثر اطلاعات کلیدی، این مطالعه به تحلیل دو نوع خلاصه‌سازی، یعنی استخراجی و انتزاعی، می‌پردازد. در این راستا، ابتدا مجموعه داده‌های متنوعی از مقالات علمی جمع‌آوری و پیش‌پردازش شده و سپس مدل‌های مختلف ترانسفورمر برای تولید خلاصه‌های دقیق و کارآمد به کار گرفته می‌شوند. نتایج حاصل از ارزیابی‌های کمی و کیفی نشان‌دهنده بهبود قابل توجه در دقت و کیفیت خلاصه‌ها نسبت به روش‌های سنتی است. این پژوهش نه تنها به درک بهتر فرآیند خلاصه‌سازی کمک می‌کند، بلکه راهکارهای نوینی برای تسهیل دسترسی به اطلاعات علمی ارائه می‌دهد و به‌عنوان مبنایی برای تحقیقات آینده در این حوزه محسوب می‌شود.

واژه‌های کلیدی: خلاصه‌سازی متن، مدل‌های ترانسفورمر، پردازش زبان طبیعی، یادگیری عمیق، یادگیری ماشین،

فهرست مطالب

چکیده	۱
فصل ۱ : روش پژوهش	
۱-۱ مقدمه	۲
۱-۲ پیشینه پژوهشی	۲
فصل ۲ : مبانی نظری	
۲-۱ مقدمه	۵
۲-۲ مروری بر خلاصه سازی متن	۵
۲-۳ انواع خلاصه سازی	۶
۲-۳-۱ خلاصه سازی استخراجی	۶
۲-۳-۲ خلاصه سازی انتزاعی	۷
۲-۳-۳ مقایسه روش استخراجی و انتزاعی	۸
۲-۴ پیشرفت های پردازش زبان طبیعی	۸
۲-۴-۱ توسعه های اولیه در NLP	۸
۲-۴-۲ ظهور یادگیری ماشین و یادگیری عمیق	۹
۲-۴-۳ ترنسفورمرها و مدل های زبانی پیش آموخته	۹
۲-۴-۴ نوآوری ها و کاربردهای اخیر	۱۰
۲-۵ ترانسفورمرها در خلاصه سازی متن	۱۱
۲-۵-۱ معماری ترنسفورمرها	۱۱
۲-۵-۲ نحوه عملکرد ترنسفورمرها	۱۲
۲-۶ کارهای مرتبط در خلاصه سازی مقالات علمی	۱۳
فصل ۳ : روش پژوهش	

۳-۱	مقدمه	15
۳-۲	گردآوری داده ها	15
۳-۲-۱	توصیف مجموعه داده ها	15
۳-۲-۲	مراحل پیش پردازش	16
۳-۳	انتخاب مدل	17
۳-۳-۱	مروری بر مدل های ترنسفورمر	17
۳-۳-۲	مدل های انتخاب شده	17
۳-۴	جزئیات پیاده سازی	19
۳-۴-۱	کتابخانه های مورد استفاده	19
۳-۴-۲	انتخاب هایپرپارامتر های مدل	20
۳-۵	معیار های ارزیابی	20
۳-۵-۱	امتیاز ROUGE	20
فصل ۴ : نتیجه گیری و پیشنهاد ها		
۴-۱	نتیجه گیری	23
۴-۲	پیشنهاد ها	24
	مراجع	26

فصل ۱

معرفی پژوهش

۱-۱ مقدمه

در عصر حاضر، با گسترش روزافزون تولید اطلاعات علمی و افزایش حجم مقالات منتشر شده، نیاز به روش‌های مؤثر برای خلاصه‌سازی و استخراج اطلاعات کلیدی از این متون به شدت احساس می‌شود. خلاصه‌سازی متن به عنوان یک ابزار حیاتی برای تسهیل دسترسی به اطلاعات و ارتقاء کارایی پژوهشگران و دانشجویان در فرآیند مطالعه و تحلیل داده‌ها شناخته می‌شود. این تحقیق به بررسی روش‌های نوین خلاصه‌سازی متن، به ویژه در زمینه مقالات علمی، می‌پردازد و بر استفاده از مدل‌های پیشرفته ترانسفورمر تأکید دارد. این مدل‌ها به دلیل قابلیت‌های بالای خود در درک و تولید زبان طبیعی، پتانسیل بالایی برای بهبود کیفیت خلاصه‌ها دارند. در این راستا، هدف اصلی این پژوهش توسعه و ارزیابی الگوریتم‌های خلاصه‌سازی است که بتوانند به‌طور مؤثر و دقیق، اطلاعات کلیدی را از مقالات علمی استخراج کنند و در نهایت، به بهبود فرآیند یادگیری و پژوهش در این حوزه کمک نمایند.

۱-۲ پیشینه پژوهشی

خلاصه‌سازی مقالات علمی به عنوان یک چالش مهم در پردازش زبان طبیعی (NLP) شناخته می‌شود، که به دلیل حجم بالای اطلاعات و پیچیدگی‌های موجود در متون علمی، نیاز به روش‌های مؤثر و کارآمد برای استخراج اطلاعات کلیدی را افزایش می‌دهد. با توجه به پیشرفت‌های اخیر در یادگیری عمیق و به‌ویژه مدل‌های ترانسفورمر، این روش‌ها به عنوان ابزارهای جدید برای بهبود کیفیت خلاصه‌سازی متن معرفی شده‌اند.

مقاله "Abstractive text summarization: State of the art, challenges, and improvements" منتشر شده در ScienceDirect، تکنیک‌های کلیدی در خلاصه‌سازی متن انتزاعی، مانند مدل‌های دنباله به دنباله را بررسی می‌کند، و چالش‌هایی مانند سازگاری واقعی را برجسته می‌کند و بر استراتژی‌های نوآورانه برای پیشبرد پیشرفت‌های آینده تأکید می‌کند.

مقاله "Fine Tuning Pretrained Transformers for Abstractive News Summarization" منتشر شده در IEEE، مدل‌های T5، GPT-2، و BART را برای خلاصه‌سازی اخبار با استفاده از تکنیک‌هایی مانند یادگیری انتقال مقایسه می‌کند. همچنین این مقاله به چالش‌های بهینه‌سازی هایپرپارامترها اشاره می‌کند و نشان می‌دهد که مدل T5 در مجموعه داده‌های CNN/Daily Mail عملکرد بهتری نسبت به سایر مدل‌ها داشته است.

با این حال، علی‌رغم پیشرفت‌های اخیر، هنوز چالش‌هایی در این حوزه وجود دارد. بسیاری از روش‌های موجود به محدودیت‌های خاصی در زمینه دقت و قابلیت تعمیم برخورد می‌کنند و نیاز به داده‌های آموزشی بزرگ و متنوع دارند. همچنین، نواقص موجود در ارزیابی کیفیت خلاصه‌ها و عدم توجه به زمینه‌های خاص مقالات علمی، از دیگر مشکلاتی است که در تحقیقات پیشین دیده شده است. این تحقیق با هدف پر کردن این شکاف‌ها و بهبود فرآیند خلاصه‌سازی مقالات علمی از طریق فاین‌تیون کردن ترانسفورمرهای از پیش آموزش‌دیده‌شده، به بررسی و تحلیل روش‌های مختلف می‌پردازد و به دنبال ارائه راهکارهایی برای افزایش دقت و کیفیت خلاصه‌ها در این زمینه است.

فصل ۲

مبانی نظری

۱-۲ مقدمه

این فصل به بررسی و تحلیل پیشینه تحقیق در زمینه خلاصه‌سازی متن می‌پردازد. با توجه به افزایش روزافزون حجم اطلاعات علمی و نیاز به استخراج سریع و مؤثر اطلاعات کلیدی، خلاصه‌سازی متن به عنوان یک ابزار ضروری در پردازش زبان طبیعی شناخته می‌شود. این فصل به دو نوع اصلی خلاصه‌سازی، یعنی استخراجی و انتزاعی، می‌پردازد و به بررسی مزایا و معایب هر یک می‌پردازد. همچنین، تکنیک‌های نو و پیشرفته‌ای که در سال‌های اخیر در این زمینه توسعه یافته‌اند، از جمله مدل‌های ترانسفورمر و یادگیری عمیق، مورد بررسی قرار می‌گیرند. در این راستا، چالش‌ها و محدودیت‌های موجود در روش‌های خلاصه‌سازی نیز تحلیل می‌شود تا زمینه‌ای برای شناسایی نقاط ضعف و فرصت‌های بهبود فراهم گردد. هدف این فصل، ارائه یک نمای کلی از وضعیت کنونی تحقیقات در حوزه خلاصه‌سازی متن و شناسایی روندهای نوظهور و زمینه‌های تحقیقاتی آینده است که می‌تواند به پیشرفت‌های بیشتر در این حوزه کمک کند.

۲-۲ مروری بر خلاصه‌سازی متن

خلاصه‌سازی متن به عنوان یک تکنیک کلیدی در پردازش زبان طبیعی (NLP) شناخته می‌شود که هدف آن تولید نسخه‌ای مختصر از یک متن طولانی است، بدون از دست دادن اطلاعات اصلی و مهم آن. با توجه به رشد سریع حجم داده‌های متنی در دنیای دیجیتال، نیاز به روش‌های مؤثر برای خلاصه‌سازی اطلاعات به شدت احساس می‌شود. به طور کلی، خلاصه‌سازی متن به دو نوع اصلی تقسیم می‌شود: خلاصه‌سازی استخراجی و خلاصه‌سازی انتزاعی. در خلاصه‌سازی استخراجی، جملات یا عبارات مهم مستقیماً از متن اصلی انتخاب و در یک خلاصه ترکیب می‌شوند، در حالی که در خلاصه‌سازی انتزاعی، ایده‌های کلیدی متن اصلی به صورت جملات جدیدی تولید می‌شوند که ممکن است عبارات و جملات جدیدی را شامل شوند. خلاصه‌سازی استخراجی به دلیل سادگی و کارایی خود، به طور گسترده‌ای مورد استفاده قرار می‌گیرد، اما محدودیت‌هایی نیز دارد، از جمله عدم توانایی در تولید جملات جدید و ناتوانی در درک عمیق‌تر متن. از سوی دیگر، خلاصه‌سازی انتزاعی به دلیل قابلیت تولید جملات جدید و انعطاف‌پذیری بیشتر در بیان مفاهیم، به طور فزاینده‌ای محبوب شده است و به عنوان یک حوزه تحقیقاتی فعال در نظر گرفته می‌شود. این فصل به بررسی روش‌ها و تکنیک‌های مختلف خلاصه‌سازی متن، چالش‌ها و فرصت‌های موجود در این حوزه می‌پردازد و سعی دارد تا زمینه‌ای برای تحقیقات آینده فراهم آورد. با توجه به چالش‌هایی مانند عدم دقت در نمایندگی معنایی و نیاز به ارزیابی‌های دقیق‌تر، این مطالعه به دنبال شناسایی روندهای نوظهور و راهکارهای بهبود در خلاصه‌سازی متن است.

۲-۳ انواع خلاصه‌سازی

خلاصه‌سازی متن یک حوزه مهم در پردازش زبان طبیعی (NLP) است که هدف آن فشرده‌سازی حجم‌های بزرگ متن به خلاصه‌های کوتاه و منسجم در حالی که اطلاعات اساسی حفظ می‌شود، است. دو نوع عمده تکنیک‌های خلاصه‌سازی شامل **خلاصه‌سازی استخراجی** و **خلاصه‌سازی انتزاعی** هستند. هر روش از الگوریتم‌ها و رویکردهای متفاوتی برای تولید خلاصه‌ها استفاده می‌کند و درک تفاوت‌های آن‌ها برای انتخاب تکنیک مناسب برای کاربردهای خاص بسیار مهم است.

۲-۳-۱ خلاصه‌سازی استخراجی

خلاصه‌سازی استخراجی شامل انتخاب و ترکیب جملات یا عبارات مرتبط‌ترین از متن اصلی برای ایجاد یک خلاصه است. این روش بر این فرض استوار است که جملات اطلاعاتی‌ترین در متن اصلی از قبل موجود هستند. الگوریتم‌های مورد استفاده برای خلاصه‌سازی استخراجی را می‌توان به چندین رویکرد تقسیم کرد :

- **روش‌های مبتنی بر فراوانی**: این روش‌ها، مانند فراوانی اصطلاحات-معکوس فراوانی سند (TF-IDF)، اهمیت جملات را بر اساس فراوانی اصطلاحاتی که در آن‌ها وجود دارد، ارزیابی می‌کنند. جملات با فراوانی بالاتر از اصطلاحات به عنوان مهم‌تر در نظر گرفته می‌شوند و برای گنجاندن در خلاصه انتخاب می‌شوند.
- **روش‌های مبتنی بر گراف**: تکنیک‌هایی مانند TextRank و LexRank از ساختارهای گرافی برای نمایش جملات به عنوان گره‌ها و روابط آن‌ها به عنوان لبه‌ها استفاده می‌کنند. اهمیت هر جمله بر اساس ارتباط آن با سایر جملات در گراف تعیین می‌شود و جملات مرکزی‌تر برای خلاصه انتخاب می‌شوند. این روش‌ها از الگوریتم‌های PageRank که در موتورهای جستجوی وب استفاده می‌شوند، الهام گرفته‌اند.
- **رویکردهای یادگیری ماشین**: تکنیک‌های یادگیری نظارت‌شده نیز می‌توانند به کار گرفته شوند، جایی که مدل‌ها بر روی مجموعه‌های داده برچسب‌گذاری شده آموزش می‌بینند تا جملات کلیدی را شناسایی کنند. الگوریتم‌هایی مانند ماشین‌های بردار پشتیبان (SVM) و شبکه‌های عصبی برای طبقه‌بندی جملات بر اساس مرتبط بودن آن‌ها به کار رفته‌اند.

در حالی که خلاصه‌سازی استخراجی ساده است و معمولاً خروجی‌های گرامری درستی تولید می‌کند، محدودیت‌هایی نیز دارد. خلاصه‌های حاصل ممکن است فاقد انسجام و روانی باشند، زیرا آن‌ها صرفاً از متن اصلی بدون بازنویسی یا ترکیب به هم چسبیده‌اند. علاوه بر این، روش‌های استخراجی ممکن است اطلاعات مهمی که به‌طور صریح در جملات انتخاب‌شده بیان نشده‌اند را از دست بدهند.

۲-۳-۲ خلاصه سازی انتزاعی

در مقابل، خلاصه سازی انتزاعی جملات جدیدی تولید می کند که جوهره متن اصلی را در بر می گیرد. این رویکرد به دنبال درک محتوا و تولید خلاصه ای است که ممکن است شامل بازنویسی یا عبارات جدید باشد. خلاصه سازی انتزاعی شامل الگوریتم های پیچیده تری است، از جمله :

- **مدل های توالی به توالی** : این مدل ها که معمولاً بر اساس شبکه های عصبی بازگشتی (RNN) یا شبکه های حافظه بلندمدت و کوتاه مدت (LSTM) هستند، متن ورودی را به یک بردار با طول ثابت کدگذاری کرده و آن را به یک خلاصه رمزگشایی می کنند. مکانیزم توجه معمولاً برای تمرکز بر بخش های مرتبط ورودی در حین رمزگشایی به کار می رود .

- **ترنسفورمرها** : ظهور معماری های ترنسفورمر، مانند BERT و GPT ، پیشرفت های قابل توجهی را در خلاصه سازی انتزاعی به ارمغان آورده است. ترنسفورمرها از مکانیزم های خودتوجه برای به دست آوردن وابستگی های بلندمدت در متن استفاده می کنند و به آن ها امکان تولید خلاصه های منسجم تر و مرتبط تر با متن را می دهند . مدل هایی مانند T5 و BART نتایج چشمگیری در تولید خلاصه های شبیه به انسان نشان داده اند .

- **رویکردهای ترکیبی** : برخی از مطالعات اخیر تکنیک های استخراجی و انتزاعی را ترکیب می کنند تا از نقاط قوت هر دو روش بهره برداری کنند. به عنوان مثال، یک مرحله استخراجی ممکن است ابتدا جملات کلیدی را شناسایی کند و سپس یک مرحله انتزاعی این جملات را به یک خلاصه منسجم بازنویسی و ترکیب کند .

خلاصه سازی انتزاعی معمولاً خلاصه های روان تر و شبیه به انسان تری تولید می کند، اما پیاده سازی آن نیز چالش برانگیزتر است. مدل ها نیاز به آموزش گسترده بر روی مجموعه های داده بزرگ دارند و ممکن است با دقت واقعی مشکل داشته باشند و گاهی اطلاعاتی تولید کنند که در متن اصلی وجود ندارد.

۳-۳-۲ مقایسه روش استخراجی و انتزاعی

ویژگی	خلاصه سازی استخراجی	خلاصه سازی انتزاعی
روش	جملات را به طور مستقیم از متن انتخاب می کند.	جملات جدیدی بر اساس درک تولید می کند.
پیچیدگی	ساده تر، وابسته به انتخاب جملات	پیچیده تر، شامل تولید زبان است
انسجام	ممکن است به دلیل استخراج مستقیم فاقد انسجام باشد	معمولاً انسجام و روانی بیشتری دارد
دقت	بالا، زیرا از جملات اصلی استفاده می کند	متغیر، ممکن است نادرستی هایی را معرفی کند
منابع محاسباتی	به منابع بیشتری برای آموزش و استنباط نیاز دارد	معمولاً به منابع محاسباتی کمتری نیاز دارد

۴-۲ پیشرفت های پردازش زبان طبیعی

پردازش زبان طبیعی (NLP) از زمان تأسیس خود تحولات قابل توجهی را تجربه کرده است و از سیستم های ابتدایی مبتنی بر قوانین به مدل های پیچیده ای که قادر به درک و تولید متنی شبیه به انسان هستند، تکامل یافته است. این بخش تحولات کلیدی در NLP را بررسی می کند و پیشرفت های بنیادی و نوآوری های اخیر را که این حوزه را شکل داده اند، مورد توجه قرار می دهد.

۴-۲-۱ توسعه های اولیه در NLP

ریشه های NLP به دهه ۱۹۵۰ و ۱۹۶۰ برمی گردد، زمانی که تحقیقات اولیه بر روی ترجمه ماشینی و تجزیه نحوی متمرکز بود. یکی از سیستم های اولیه قابل توجه، آزمایش Georgetown-IBM در سال ۱۹۵۴ بود که توانایی ترجمه جملات روسی به انگلیسی را با استفاده از واژگان و قوانین گرامری محدود نشان داد. این دوره پایه گذار تحقیقات آینده در NLP بود، اما با چالش هایی به دلیل پیچیدگی زبان انسانی و محدودیت های قدرت محاسباتی مواجه بود. در دهه های ۱۹۷۰ و ۱۹۸۰، معرفی دستور زبان های رسمی، مانند دستور زبان تولیدی چامسکی، چارچوب نظری برای درک ساختار زبان فراهم کرد. با این حال، این رویکردهای مبتنی بر قوانین با ابهام و تنوع در زبان طبیعی دست و پنجه نرم کردند و منجر به بررسی روش های آماری در دهه ۱۹۹۰ شدند. ظهور NLP آماری یک تغییر پارادایمی را به همراه داشت، به طوری که پژوهشگران شروع به استفاده از مجموعه های بزرگ متنی برای توسعه مدل های احتمالی برای وظایفی مانند برچسب گذاری بخش های گفتار و شناسایی موجودیت های نام دار (NER) کردند.

۲-۴-۲ ظهور یادگیری ماشین و یادگیری عمیق

اوایل دهه ۲۰۰۰ شاهد ادغام تکنیک‌های یادگیری ماشین در NLP بود که به طور قابل توجهی عملکرد در زمینه‌های مختلف را بهبود بخشید. ماشین‌های بردار پشتیبان (SVM) و میدان‌های تصادفی شرطی (CRF) به عنوان ابزارهای محبوب برای وظایف طبقه‌بندی تبدیل شدند، در حالی که الگوریتم‌هایی مانند مدل‌های مخفی مارکوف (HMM) برای وظایف برچسب‌گذاری توالی به کار گرفته شدند. این روش‌ها به سیستم‌ها این امکان را می‌دادند که از داده‌ها یاد بگیرند و نه تنها به قوانین دست‌نویس وابسته باشند، که منجر به توسعه برنامه‌های NLP قوی‌تر و سازگارتر شد. ورود یادگیری عمیق در دهه ۲۰۱۰ انقلاب بزرگی در NLP ایجاد کرد. شبکه‌های عصبی، به ویژه شبکه‌های عصبی بازگشتی (RNN) و انواع آن‌ها، مانند شبکه‌های حافظه بلندمدت و کوتاه‌مدت (LSTM)، امکان بهتری برای مدیریت داده‌های توالی‌دار فراهم کردند و آن‌ها را برای وظایفی مانند مدل‌سازی زبان و ترجمه ماشینی مناسب ساختند. کار برجسته باه‌دانائو و همکاران (۲۰۱۴) مکانیزم توجه را معرفی کرد که کیفیت ترجمه را به طور قابل توجهی بهبود بخشید و به مدل‌ها این امکان را داد که بر بخش‌های مرتبط از توالی ورودی تمرکز کنند.

۲-۴-۳ ترنسفورمرها و مدل‌های زبانی پیش‌آمोخته

انتشار معماری ترنسفورمر توسط واسوانی و همکاران در سال ۲۰۱۷ نقطه عطفی در NLP بود. ترنسفورمرها از مکانیزم‌های خودتوجه برای پردازش داده‌های ورودی به صورت موازی استفاده می‌کنند که به طور قابل توجهی کارایی آموزش و عملکرد را در طیف وسیعی از وظایف بهبود می‌بخشد. این معماری زمینه‌ساز توسعه مدل‌های زبانی پیش‌آمोخته شد که به سنگ بنای NLP مدرن تبدیل شده‌اند. مدل‌هایی مانند BERT (نمایش‌های دوجهته از ترنسفورمرها) و GPT (ترنسفورمر پیش‌آمोخته تولیدی) قابلیت‌های قابل توجهی در درک زمینه و تولید متن منسجم نشان داده‌اند BERT.، که توسط دوولین و همکاران (۲۰۱۸) معرفی شد، از تکنیک مدل‌سازی زبان ماسک‌شده استفاده می‌کند که به آن اجازه می‌دهد نمایش‌های دوجهته‌ای از متن یاد بگیرد و منجر به عملکرد پیشرفته در معیارهای مختلف شود. به طور مشابه، GPT-3 که توسط OpenAI منتشر شد، پتانسیل مدل‌های زبانی در مقیاس بزرگ را نشان داد و قادر به تولید متنی شبیه به انسان در پاسخ به درخواست‌های متنوع و کاربردهای مختلف بود.

۴-۴-۲ نوآوری‌ها و کاربردهای اخیر

در سال‌های اخیر، حوزه NLP به تکامل خود ادامه داده و پیشرفت‌های قابل توجهی در چندین زمینه داشته است :

- **هوش مصنوعی مکالمه‌ای:** توسعه چت‌بات‌ها و دستیاران مجازی پیشرفته، تعاملات مشتری را در صنایع مختلف متحول کرده است. این سیستم‌ها از NLP برای درک پرسش‌های کاربر و ارائه پاسخ‌های مرتبط استفاده می‌کنند و تجربه کاربری را بهبود می‌بخشند .

- **تولید زبان طبیعی (NLG):** در ایجاد محتوای خودکار به محبوبیت رسیده و به سازمان‌ها این امکان را می‌دهد که متن‌های شبیه به انسان را از داده‌های ساختاری تولید کنند. این فناوری به‌ویژه در روزنامه‌نگاری و مالی، جایی که گزارش‌دهی به‌موقع و دقیق حیاتی است، مفید است .

- **تحلیل احساسات و شناسایی عواطف:** پیشرفت‌ها در تحلیل احساسات توانایی سیستم‌ها را در درک و پاسخ به تن‌های احساسی در ارتباطات بهبود بخشیده است. این قابلیت به‌طور فزاینده‌ای در خدمات مشتری و نظارت بر رسانه‌های اجتماعی مورد استفاده قرار می‌گیرد .

- **یادگیری چندمدالیت‌های:** تحقیقات اخیر به بررسی ادغام NLP با سایر مدالیت‌ها، مانند داده‌های بصری و شنیداری پرداخته است که منجر به سیستم‌های درک جامع‌تری می‌شود. این روند با مدل‌هایی که می‌توانند هم متن و هم تصاویر را پردازش کنند تا خروجی‌های مرتبط با زمینه تولید کنند، به خوبی نمایان است .

- **ملاحظات اخلاقی و کاهش تعصب:** با گسترش فناوری‌های NLP، پرداختن به نگرانی‌های اخلاقی، از جمله تعصب در مدل‌های زبانی و استقرار مسئولانه سیستم‌های NLP، به موضوعی مهم تبدیل شده است. تحقیقات جاری به توسعه چارچوب‌هایی برای اطمینان از انصاف و پاسخگویی در کاربردهای NLP می‌پردازد .

پیشرفت‌ها در پردازش زبان طبیعی به‌طور قابل توجهی شیوه تعامل ماشین‌ها با زبان انسانی را متحول کرده است. از سیستم‌های ابتدایی مبتنی بر قوانین تا مدل‌های پیشرفته یادگیری عمیق کنونی، این حوزه شاهد پیشرفت‌های قابل توجهی بوده است. با ادامه تکامل NLP، تحقیقات و نوآوری‌های مداوم برای مقابله با چالش‌ها و باز کردن امکانات جدید برای کاربردها در زمینه‌های مختلف ضروری خواهد بود.


۵-۲ ترانسفورمرها در خلاصه سازی متن

ترانسفورمرها انقلاب بزرگی در حوزه پردازش زبان طبیعی (NLP) به‌ویژه در زمینه خلاصه‌سازی متن ایجاد کرده‌اند. معماری منحصر به فرد و مکانیزم توجه آن‌ها به آن‌ها این امکان را می‌دهد که روابط بین کلمات در یک توالی را به‌طور مؤثری شناسایی کنند، که این امر آن‌ها را نسبت به مدل‌های قبلی مانند شبکه‌های عصبی بازگشتی (RNN) و شبکه‌های حافظه بلندمدت و کوتاه‌مدت (LSTM) برتر می‌سازد. این بخش به بررسی معماری ترانسفورمرها، نحوه عملکرد آن‌ها و کاربردهای آن‌ها در خلاصه‌سازی متن می‌پردازد.

۱-۵-۲ معماری ترانسفورمرها

معماری ترانسفورمر که در مقاله "توجه، همه آن چیزی است که نیاز دارید" توسط واسوانی و همکاران (2017) معرفی شد، شامل یک ساختار کدگذار-رمزگذار است.

کدگذار متن ورودی را پردازش کرده و آن را به یک نمایش پیوسته تبدیل می‌کند که اطلاعات اساسی را در بر می‌گیرد. این بخش شامل چندین لایه است که هر یک از دو مؤلفه اصلی تشکیل شده‌اند: توجه خودی چندسر و یک شبکه عصبی پیش‌خور. رمزگذار توالی خروجی (خلاصه) را از نمایش کدگذاری شده تولید می‌کند. این بخش نیز شامل چندین لایه است و دارای یک مکانیزم توجه اضافی است که به آن اجازه می‌دهد بر بخش‌های مرتبط با ورودی تمرکز کند.



۲-۵-۲ نحوه عملکرد ترنسفورمرها

نوآوری اصلی ترنسفورمرها در مکانیزم توجه آن‌ها نهفته است که به مدل این امکان را می‌دهد تا اهمیت کلمات مختلف در یک توالی را هنگام تولید یک خلاصه ارزیابی کند. این کار از طریق مراحل زیر انجام می‌شود:

۱. **تبدیل ورودی به بردار**: متن ورودی ابتدا به نمایش‌های برداری تبدیل می‌شود که از یک لایه تعبیه استفاده می‌کند. هر کلمه به یک بردار پیوسته که معنی معنایی آن را در بر می‌گیرد، نگاشته می‌شود.

۲. **کدگذاری موقعیتی**: از آنجا که ترنسفورمرها به‌طور ذاتی ترتیب کلمات را درک نمی‌کنند، کدگذاری موقعیتی به تعبیه‌ها اضافه می‌شود. این کدگذاری از توابع سینوس و کسینوس برای ارائه اطلاعات در مورد موقعیت هر کلمه در توالی استفاده می‌کند.

۳. **مکانیزم توجه خودی**: مکانیزم توجه خودی به مدل این امکان را می‌دهد که روابط بین کلمات در توالی ورودی را محاسبه کند. برای هر کلمه، سه بردار ایجاد می‌شود: پرسش (QQ)، کلید (KK) و ارزش (VV). نمرات توجه با استفاده از حاصل ضرب نقطه‌ای بین بردارهای پرسش و کلید محاسبه می‌شود:

$$\text{Attention}(Q,K,V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

در اینجا، d_k بعد بردارهای کلید است و تابع softmax برای به‌دست‌آوردن وزن‌های توجه که تعیین می‌کند هر کلمه چقدر باید بر اساس ارتباطش با کلمات دیگر تمرکز کند، اعمال می‌شود.

۴. **توجه چندسری**: به‌جای انجام یک تابع توجه، ترنسفورمرها از چندین سری توجه برای شناسایی انواع مختلف روابط استفاده می‌کنند. هر سری به‌طور مستقل ورودی را پردازش می‌کند و به مدل این امکان را می‌دهد که جنبه‌های مختلف داده را یاد بگیرد. خروجی‌های همه سری‌ها ترکیب و به‌صورت خطی تبدیل می‌شوند تا خروجی نهایی لایه توجه را تشکیل دهند.

۵. **شبکه پیش‌خور**: پس از لایه توجه، خروجی از طریق یک شبکه عصبی پیش‌خور عبور می‌کند که شامل دو تبدیل خطی با یک تابع فعال‌سازی ReLU در بین آن‌ها است. این شبکه اطلاعات را بیشتر پردازش کرده و توانایی مدل را برای شناسایی الگوهای پیچیده افزایش می‌دهد.

۶. **اتصالات باقی‌مانده و نرمال‌سازی لایه**: برای تسهیل آموزش، اتصالات باقی‌مانده به دور هر زیرلایه (توجه و پیش‌خور) اضافه می‌شود و نرمال‌سازی لایه برای تثبیت فرآیند یادگیری اعمال می‌شود.

در خلاصه‌سازی متن، ترنسفورمرها به دلیل توانایی‌شان در در نظر گرفتن کل زمینه متن ورودی، عملکرد فوق‌العاده‌ای دارند. کدگذار کل توالی ورودی را پردازش می‌کند و روابط بین تمام کلمات را شناسایی می‌کند، در حالی که رمزگذار خلاصه را با تمرکز بر بخش‌های مرتبط با ورودی تولید می‌کند. ترنسفورمرها می‌توانند بر روی مجموعه‌های بزرگ داده‌ای از مقالات علمی یا مقالات آموزشی تنظیم شوند تا خلاصه‌های با کیفیت بالا تولید کنند.

۶-۲ کارهای مرتبط در خلاصه‌سازی مقالات علمی

در سال‌های اخیر، حوزه خلاصه‌سازی متن شاهد پیشرفت‌های قابل توجهی بوده است، به‌ویژه با معرفی مدل‌های ترنسفورمر. این مدل‌ها شیوه تولید خلاصه‌ها را متحول کرده و با استفاده از معماری منحصر به فرد و مکانیزم‌های توجه خود، روابط پیچیده درون متن را شناسایی می‌کنند. تحقیقات نشان داده‌اند که ترنسفورمرها، مانند BERT و GPT، در وظایف خلاصه‌سازی استخراجی و انتزاعی عملکرد بسیار خوبی دارند و در مقایسه با روش‌های سنتی از نظر انسجام و مرتبط بودن برتری دارند. مطالعات مختلف به بررسی کاربرد ترنسفورمرها در خلاصه‌سازی مقالات علمی، مقالات خبری و سایر اشکال متن پرداخته‌اند و اثربخشی و تنوع آن‌ها را نشان داده‌اند. بررسی‌های مداوم در مورد رویکردهای مبتنی بر ترنسفورمر همچنان تکنیک‌ها و روش‌های جدیدی را آشکار می‌کند و به تحول در حوزه خلاصه‌سازی متن کمک می‌کند و معیارهای جدیدی برای تحقیقات آینده در این زمینه تعیین می‌کند.

لیو و لاپاتا روشی را برای خلاصه‌سازی متن با استفاده از مدل‌های BERT از پیش آموزش دیده پیشنهاد کردند. آن‌ها یک رمزگذار جدید در سطح سند مبتنی بر BERT برای درک معنایی یک سند و به دست آوردن بازنمایی جملات معرفی کردند. رویکرد آن‌ها شامل هر دو مدل خلاصه‌سازی استخراجی و انتزاعی است. مدل استخراجی از لایه‌های ترانسفورماتور بین جمله‌ای استفاده می‌کند، در حالی که مدل انتزاعی از یک برنامه تنظیم دقیق جدید با بهینه‌سازی جداگانه برای رمزگذار و رمزگشا استفاده می‌کند. این روش بر روی سه مجموعه داده مورد ارزیابی قرار گرفت و به نتایج پیشرفته‌ای در هر دو محیط استخراجی و انتزاعی دست یافت.

خاندلوال و همکاران روشی را برای خلاصه‌سازی متن کارآمد با استفاده از یک ترانسفورماتور از پیش آموزش دیده پیشنهاد کرد. این رویکرد از یک شبکه فقط رمزگشا استفاده می‌کند که در آن همان Transformer LM منبع را رمزگذاری می‌کند و خلاصه را تولید می‌کند. با استفاده از نمرات ROUGE در مجموعه داده‌های CNN/Daily Mail مورد ارزیابی قرار گرفت که نشان دهنده پیشرفت‌های قابل توجهی در کارایی نمونه است. مدل ROUGE-2 13.1 را تنها با استفاده از 1 درصد از داده‌های آموزشی به دست آورد، که به طور قابل توجهی بهتر از مدل‌های رمزگذار-رمزگشا از قبل آموزش دیده عمل کرد.

فصل ۳

روش پژوهش

۳-۱ مقدمه

این پروژه به طور خاص بر روی استخراج و خلاصه سازی محتوا از فایل های XML تمرکز دارد و تحلیل مقایسه ای از مدل های مختلف خلاصه سازی، از جمله Longformer، BigBird-Pegasus و یک مدل فاین تیون شده را انجام می دهد.

این روند با با آماده سازی داده ها آغاز می شود، جایی که فایل های XML پردازش می شوند تا چکیده ها و محتوای اصلی مقالات استخراج شوند و سپس داده ها پاک سازی و به مجموعه های آموزشی، اعتبارسنجی و آزمایشی تقسیم می شوند. این کار اطمینان حاصل می کند که داده ها برای آموزش مؤثر مدل ها آماده هستند. فرآیند خلاصه سازی از کتابخانه ترنسفورمرهای Hugging Face استفاده می کند و مدل هایی را به کار می گیرد که برای مستندات طولانی و داده های متنی بزرگ بهینه سازی شده اند. عملکرد هر مدل از طریق شباهت کازین ارزیابی می شود که با استفاده از بردارهای TF-IDF محاسبه می شود تا ارزیابی کند که چقدر خلاصه های تولید شده با متن اصلی هم راستا هستند.

علاوه بر این، تنظیم های پارامترها برای بهینه سازی نرخ های یادگیری، اندازه های بچ و پیکربندی های مدل انجام می شود تا دقت خلاصه سازی به حداکثر برسد. هدف نهایی این است که این مدل ها را بهبود بخشیده و قابلیت های خلاصه سازی آن ها را افزایش دهیم، به طوری که استفاده از اطلاعات در زمینه های مختلف، از جمله تحقیقات علمی، تسهیل شود.

۳-۲ گردآوری داده ها

در مرحله گردآوری داده ها، فایل های XML پردازش شدند تا چکیده ها و محتوای اصلی مرتبط استخراج شود. سپس داده ها پاک سازی و به مجموعه های آموزشی، اعتبارسنجی و آزمایشی تقسیم شدند تا یک مجموعه داده قوی برای آموزش و ارزیابی مدل های خلاصه سازی فراهم شود.

۳-۲-۱ توصیف مجموعه داده ها

مجموعه داده ای که در این پروژه استفاده شده، از PubMed Central® (PMC) استخراج شده است، که یک مخزن جامع از ژورنال های علمی مجلات بیومدیکال است که توسط کتابخانه ملی پزشکی مؤسسه های ملی بهداشت ایالات متحده نگهداری می شود. PMC به عنوان یک منبع حیاتی برای تحقیقات معاصر بیومدیکال و مراقبت های بهداشتی عمل می کند و دسترسی به مجموعه وسیعی از مقالات را فراهم می آورد که از مطالعات جاری و تلاش های علمی آینده پشتیبانی می کند. این مجموعه داده شامل دامنه ای متنوع از مقالات در

فرمت XML است، که فرآیند استخراج و پردازش داده‌ها را برای خلاصه‌سازی تسهیل می‌کند. این فرمت ساختاریافته امکان تحلیل سیستماتیک چکیده‌ها و محتوای اصلی را فراهم می‌آورد و اطمینان حاصل می‌کند که مدل‌های خلاصه‌سازی می‌توانند به‌طور مؤثری بر روی داده‌های با کیفیت بالا آموزش ببینند.

۲-۲-۳ مراحل پیش‌پردازش

مرحله پیش‌پردازش این پروژه شامل مجموعه‌ای از مراحل برای آماده‌سازی مجموعه داده‌ها برای تنظیم و ارزیابی مدل بود.

اولین مرحله شامل دانلود انبوه فایل‌های XML مرتبط از PMC بود. این فایل‌ها سپس پردازش و به فرمت JSON تبدیل شدند که بر روی استخراج دو مؤلفه کلیدی تمرکز داشت: چکیده مقاله، که از بخش چکیده استخراج شده، و متن اصلی مقاله، که شامل متن کامل به‌جز چکیده است. این فرآیند تبدیل به‌منظور ساده‌سازی مراحل بعدی پاک‌سازی و آماده‌سازی داده‌ها انجام شد.

برای اطمینان از سازگاری، یکپارچگی و خوانایی، چندین تکنیک رایج پاک‌سازی داده‌ها به کار گرفته شد. کاراکترهای غیر ASCII از متن حذف شدند، برچسب‌های XML برای جداسازی محتوای مرتبط حذف شدند و فضاهای خالی و خط‌های جدید مناسب برای بهبود فرمت‌بندی اضافه شدند.

پس از پاک‌سازی اولیه، پنج رویکرد مختلف برای آماده‌سازی بیشتر داده‌ها برای تنظیم مدل به کار گرفته شد. این رویکردها در کاربرد لِماتیزاسیون، حذف کلمات توقف و نحوه برخورد با محتوای چکیده در متن اصلی متفاوت بودند. دلیل این رویکردها بررسی تأثیر تکنیک‌های مختلف پاک‌سازی بر عملکرد مدل و شناسایی بهترین ترکیب برای خلاصه‌سازی مقالات بیومدیکال بود.

رویکرد اول شامل لِماتیزاسیون هر دو متن چکیده و متن اصلی، حذف کلمات توقف از هر دو بخش و حذف محتوای چکیده از متن اصلی برای جلوگیری از تکرار بود. رویکرد دوم تنها لِماتیزاسیون و حذف کلمات توقف را بر روی متن اصلی اعمال کرد و همچنان چکیده را حذف کرد. رویکرد سوم متن کامل اصلی را شامل چکیده نگه داشت، اما لِماتیزاسیون و حذف کلمات توقف را بر روی هر دو بخش اعمال کرد. رویکرد چهارم تنها لِماتیزاسیون و حذف کلمات توقف را بر روی متن اصلی انجام داد و چکیده را حفظ کرد. در نهایت، رویکرد پنجم به سادگی محتوای چکیده را از متن اصلی حذف کرد.

با به‌کارگیری این رویکردهای مختلف پاک‌سازی، پروژه به بررسی تأثیر آن‌ها بر عملکرد مدل و تعیین بهترین ترکیب برای خلاصه‌سازی مقالات بیومدیکال پرداخت. مجموعه داده‌های پاک‌سازی‌شده که از این مراحل

پیش‌پردازش به‌دست آمدند، سپس برای تنظیم و ارزیابی عملکرد مدل‌های مختلف خلاصه‌سازی متن، از جمله Longformer، BigBird-Pegasus و مدل فاین تیون شده استفاده شد.

۳-۳ انتخاب مدل

در انتخاب مؤثرترین مدل برای خلاصه‌سازی مقالات بیومدیکال، چندین مدل پیش‌آمخته پیشرفته ارزیابی شدند. اگرچه BART به خاطر عملکرد قوی‌اش در تولید متن شناخته شده است، اما به دلیل محدودیت اندازه پنجره‌اش و حجم بالای داده‌های ورودی، برای مورد ما مناسب تشخیص داده نشد. در عوض، مدل‌هایی مانند BigBird-Pegasus و Longformer به خاطر توانایی‌شان در مدیریت کارآمد مستندات طولانی ترجیح داده شدند.

۳-۳-۱ مروری بر مدل‌های ترنسفورمر

مدل‌های ترنسفورمر انقلاب بزرگی در زمینه پردازش زبان طبیعی (NLP) ایجاد کرده‌اند و امکان مدیریت کارآمد وظایف پیچیده‌ای مانند خلاصه‌سازی متن، ترجمه و تحلیل احساسات را فراهم می‌آورند. این مدل‌ها از مکانیزم توجه خودکار استفاده می‌کنند که به آن‌ها اجازه می‌دهد اهمیت کلمات مختلف در یک جمله را بدون توجه به موقعیت آن‌ها وزن‌دهی کنند. این قابلیت به ترنسفورمرها کمک می‌کند تا وابستگی‌های بلندمدت در متن را شناسایی کنند و آن‌ها را برای درک زمینه و تولید خروجی‌های منسجم به‌ویژه مؤثر می‌سازد. مدل‌های معروف ترنسفورمر شامل BERT است که در درک زمینه عالی است و GPT که برای تولید متن طراحی شده است. علاوه بر این، مدل‌هایی مانند BART و PEGASUS به‌طور خاص برای وظایف خلاصه‌سازی بهینه‌سازی شده‌اند و عملکردی پیشرفته در بنچمارک‌های مختلف ارائه می‌دهند. انعطاف‌پذیری و قدرت معماری‌های ترنسفورمر همچنان به پیشرفت‌ها در NLP کمک می‌کند و برنامه‌های پیچیده‌تری را تسهیل می‌نماید و درک کلی زبان را بهبود می‌بخشد.


۳-۳-۲ مدل‌های انتخاب شده

مدل‌های منتخب برای خلاصه‌سازی شامل BigBird-Pegasus است که در مدیریت مستندات طولانی خوب عمل می‌کند و Longformer که برای پردازش کارآمد متون بیومدیکال گسترده به منظور تولید خلاصه‌های اطلاعاتی بهینه‌سازی شده است.

الف) BigBird-Pegasus


مدل BigBird-Pegasus یک ترنسفورمر پیشرفته است که برای مدیریت توالی‌های طولانی متن طراحی شده است و آن را برای تسک‌های خلاصه‌سازی بسیار مؤثر می‌سازد. این مدل قدرت‌های BigBird که از مکانیزم توجه پراکنده استفاده می‌کند و PEGASUS که برای خلاصه‌سازی انتزاعی بهینه‌سازی شده است را ترکیب می‌کند.

این مدل می‌تواند توالی‌هایی تا 4096 توکن را مدیریت کند که به طور قابل توجهی عملکرد را در تسک‌هایی که مستندات طولانی درگیر هستند، بهبود می‌بخشد. با کاهش پیچیدگی درجه دوم مکانیزم‌های توجه سنتی به خطی، BigBird-PEGASUS مقالات گسترده بیومدیکال را به طور کارآمد پردازش می‌کند و امکان تولید خلاصه‌های اطلاعاتی را فراهم می‌آورد. معماری آن امکان توجه جهانی و تصادفی را در کنار توجه پراکنده بلوکی فراهم می‌کند که توانایی آن را در شناسایی اطلاعات زمینه‌ای در سراسر متون بزرگ افزایش می‌دهد. این موضوع BigBird-PEGASUS را به ابزاری قدرتمند برای پژوهشگران و متخصصان در حوزه پردازش زبان طبیعی تبدیل می‌کند.




ب) Longformer


مدل Longformer یک معماری ترنسفورمر است که به‌طور خاص برای پردازش کارآمد مستندات طولانی طراحی شده است. این مدل به محدودیت‌های ترنسفورمرهای سنتی که در پردازش توالی‌های طولانی با مشکل مواجه می‌شوند، به‌ویژه به دلیل مکانیزم توجه خود که به‌صورت درجه دوم با طول توالی مقیاس می‌یابد، پاسخ می‌دهد. Longformer یک مکانیزم توجه نوآورانه معرفی می‌کند که توجه محلی (پنجره متحرک) و توجه جهانی را ترکیب می‌کند و به آن اجازه می‌دهد تا توالی‌هایی با هزاران توکن را بدون بار اضافی قابل توجه در حافظه و محاسبات پردازش کند. این مقیاس‌پذیری خطی Longformer را برای تسک‌هایی مانند خلاصه‌سازی متن و سوال و پاسخ مؤثر می‌سازد. این مدل در بنچمارک‌های مختلف عملکردی پیشرفته را نشان داده و مدل‌های قبلی مانند RoBERTa را در وظایف مرتبط با مستندات طولانی پشت سر گذاشته است و آن را به ابزاری ارزشمند در کاربردهای پردازش زبان طبیعی تبدیل می‌کند.




(a) Full n^2 attention



(b) Sliding window attention



(c) Dilated sliding window



(d) Global+sliding window

۳-۴ جزئیات پیاده‌سازی

در این بخش به بررسی کتابخانه‌های مهم مورد استفاده در پروژه و هایپرپارامترهای انتخابی می‌پردازیم.

۳-۴-۱ کتابخانه‌های مورد استفاده

این پروژه از مجموعه‌ای از کتابخانه‌ها برای تسهیل پردازش داده، آموزش مدل و ارزیابی استفاده کرد. کتابخانه‌های NumPy و Pandas برای محاسبات عددی کارآمد و دستکاری داده‌ها به کار گرفته شدند. NumPy برای عملیات آرایه و توابع ریاضی استفاده شد، Pandas امکان مدیریت داده‌های ساختاریافته در قالب DataFrame را فراهم کرد.

کتابخانه Transformers از Hugging Face نقش مهمی در این پروژه ایفا کرد. این کتابخانه دسترسی به مدل‌های پیش‌آمورخته پیشرفته‌ای مانند BART، BigBird-PEGASUS و Longformer را فراهم کرد که برای تسک خلاصه‌سازی متن بهینه‌سازی شدند. علاوه بر این، کلاس‌های Tokenizer از Transformers برای پیش‌پردازش داده‌های متنی ورودی استفاده شدند تا سازگاری با مدل‌ها تضمین شود.

فریم‌ورک یادگیری عمیق PyTorch برای آموزش و استنتاج مدل‌ها به کار گرفته شد. این فریم‌ورک انعطاف‌پذیری در تعریف و آموزش مدل‌های کاستوم شده و همچنین استفاده از شتاب‌دهی GPU برای محاسبات کارآمد را فراهم کرد. کتابخانه Datasets از Hugging Face برای بارگذاری و مدیریت مجموعه داده استفاده شد که امکان بارگذاری و دسته‌بندی کارآمد داده‌ها در طول آموزش را فراهم کرد.

کتابخانه Natural Language Toolkit (NLTK) برای انجام تسک‌های مختلف پردازش متن، مانند توکن‌سازی، حذف کلمات توقف و لماتی‌زاسیون استفاده شد. این تکنیک‌ها در طول پیش‌پردازش داده‌ها به منظور پاک‌سازی و آماده‌سازی متن برای آموزش مدل به کار گرفته شدند.

کتابخانه `scikit-learn` برای تقسیم داده‌ها استفاده شد که امکان تقسیم مجموعه داده به مجموعه‌های آموزشی، اعتبارسنجی و آزمایشی را فراهم کرد. این کار اطمینان حاصل کرد که مدل‌ها بر روی داده‌های نادیده ارزیابی شوند و ارزیابی قابل اعتمادی از عملکرد آن‌ها ارائه شود.

کتابخانه‌های دیگر مانند `tqdm` برای ردیابی پیشرفت، `Rich` برای فرمت‌بندی کنسول و `Matplotlib` برای رسم داده‌ها برای بهبود عملکرد و تجربه کاربری پروژه به کار گرفته شدند.

۲-۴-۳ انتخاب هایپرپارامترهای مدل

در این پروژه، تنظیم هایپرپارامترها مرحله مهمی در بهینه‌سازی عملکرد مدل‌های خلاصه‌سازی بود. کلاس `Seq2SeqTrainingArguments` از کتابخانه `Transformers` برای پیکربندی پارامترهای مختلف آموزش استفاده شد. دایرکتوری خروجی به `"led-arxiv-10000"` تنظیم شد که امکان ذخیره‌سازی منظم نتایج و چک‌پوینت‌های مدل را فراهم می‌کرد.

برای اطمینان از ارزیابی مؤثر، مدل به‌گونه‌ای پیکربندی شد که هر ۳۰۰ گام در طول آموزش ارزیابی شود، با استراتژی ارزیابی تنظیم شده بر روی "گام‌ها". این رویکرد بازخورد به موقع در مورد عملکرد مدل را تسهیل کرد. فرآیند آموزش طی پنج اپوک انجام شد، با اندازه دسته آموزشی ۱ و اندازه دسته ارزیابی ۱، که استفاده از حافظه و کارایی محاسباتی را متعادل می‌کرد.

نرخ یادگیری $5e-6$ برای بهینه‌سازی مدل انتخاب شد. علاوه بر این، استفاده از اعداد اعشاری ۱۶ بیتی (`fp16`) به کاهش مصرف حافظه کمک کرد که امکان اندازه‌های دسته بزرگتر و افزایش سرعت آموزش را فراهم می‌کرد. تجمع گرادیان به ۴ گام تنظیم شد تا استفاده از حافظه را بهینه‌تر کند.

مدل به‌گونه‌ای طراحی شد که بهترین نسخه را هر ۹۰۰ گام ذخیره کند، با محدودیت کل ۵۰ مدل ذخیره‌شده. در نهایت، پیکربندی اطمینان حاصل کرد که بهترین مدل در پایان آموزش بارگذاری شود تا پتانسیل نتایج خلاصه‌سازی با کیفیت بالا را حداکثر کند.

۵-۳ معیارهای ارزیابی

ارزیابی یک مدل خلاصه‌سازی شامل ارزیابی هر دو مدل از پیش آموزش دیده و مدل دقیق تنظیم شده است تا اطمینان حاصل شود که خلاصه‌های تولید شده دقیق، منسجم و مرتبط هستند.

۱-۵-۳ امتیاز ROUGE

امتیاز `ROUGE (Recall-Oriented Understudy for Gisting Evaluation)` مجموعه‌ای از معیارهای مهم است که برای ارزیابی کیفیت سیستم‌های خلاصه‌سازی خودکار و ترجمه ماشینی استفاده می‌شود. این امتیاز

همپوشانی بین یک خلاصه تولید شده توسط سیستم و یک یا چند خلاصه مرجع انسانی را اندازه‌گیری می‌کند. امتیاز ROUGE از 0 تا 1 متغیر است، به طوری که امتیاز نزدیک‌تر به 1 نشان‌دهنده شباهت بالاتر بین خلاصه تولید شده و خلاصه‌های مرجع است.

ROUGE شامل چندین نوع است، از جمله ROUGE-N که همپوشانی n -گرام‌ها (مانند یک‌گرام‌ها و دوگرام‌ها) را ارزیابی می‌کند و ROUGE-L که طولانی‌ترین زنجیره مشترک بین دو متن را بررسی می‌کند. این معیارها بینش‌هایی درباره اینکه یک مدل خلاصه‌سازی چقدر اطلاعات کلیدی را از متن اصلی حفظ می‌کند و در عین حال خروجی‌های مختصر تولید می‌کند، ارائه می‌دهند. امتیازهای بالای ROUGE معمولاً عملکرد بهتری را نشان می‌دهند و به همین دلیل برای مقایسه مدل‌های مختلف و بهبود قابلیت‌های خلاصه‌سازی در وظایف پردازش زبان طبیعی ضروری هستند.


فصل ۴

نتیجه‌گیری و پیشنهادها

۴-۱ نتیجه گیری


این پروژه یک مطالعه مقایسه‌ای از ترنسفورمرهای محبوب پردازش زبان طبیعی برای خلاصه‌سازی متون طولانی را ارائه داده است. آزمایش‌های انجام‌شده در این مطالعه شامل تنظیم هایپرپارامترها و انواع مختلف پیش‌پردازش داده‌ها بود که نتایج امیدوارکننده‌ای در زمینه خلاصه‌سازی متون طولانی داشت. با استفاده از امتیاز ROUGE، عملکرد مدل‌های مختلف را ارزیابی کردیم و دریافتیم که حذف محتوای چکیده از بدنه متن در طی پیش‌پردازش، نتایج را به‌طور قابل‌توجهی بهبود بخشید. در کارهای آینده، بررسی رویکردهای ترکیبی که هر دو روش استخراجی و انتزاعی را ادغام می‌کنند، می‌تواند مزایای هر تکنیک را به‌کار گیرد و منجر به بهبود کیفیت خلاصه شود.

در دو تصویر زیر، نمودارهای مربوط به امتیاز ROUGE را مشاهده می‌کنید که هر کدام مربوط به یکی از نوع روش پیش‌پردازش داده‌ها هستند.



این نمودار نتیجه امتیاز ROUGE برای داده‌هایی است که با رویکرد اول پیش‌پردازش شده‌اند. رویکرد اول شامل امتیازاسیون هر دو متن چکیده و متن اصلی، حذف کلمات توقف از هر دو بخش و حذف محتوای چکیده از متن اصلی برای جلوگیری از تکرار بود.

نمودار زیر نیز نتیجه امتیاز ROUGE برای داده‌هایی است که با رویکرد پنجم پیش‌پردازش شده‌اند. رویکرد پنجم نیز به این صورت بود که محتوای چکیده را از متن اصلی حذف می‌کرد.



همانطور که مشاهده می‌کنید، شیب نمودارهای مربوط به ROUGE-1 و ROUGE-2 و ROUGE-L در شکل دوم بیشتر است یعنی به صورت صعودی به عدد یک نزدیک تر میشود که این نشان‌دهنده‌ی شباهت بیشتر خلاصه تولید شده توسط مدل فاین تیون شده و خلاصه‌ی اصلی است.

۲-۴ پیشنهادها

در حالی که نتایج این پروژه اثربخشی حذف چکیده‌ها در طی پیش‌پردازش برای خلاصه‌سازی متون علمی را نشان می‌دهد، مسیرهای متعددی برای بهبود در آینده وجود دارد. یکی از مسیرهای امیدوارکننده، بررسی رویکردهای ترکیبی است که هم تکنیک‌های استخراجی و هم انتزاعی را ترکیب می‌کند. با بهره‌گیری از قوت‌های هر روش، مانند توانایی مدل‌های استخراجی در شناسایی جملات کلیدی و ظرفیت مدل‌های انتزاعی در تولید متن جدید، ممکن است بتوان به خلاصه‌های با کیفیت بالاتر دست یافت. علاوه بر این، بهینه‌سازی و تنظیم دقیق‌تر هایپرپارامترها برای حوزه‌های خاص بیومدیکال می‌تواند منجر به نتایج خلاصه‌سازی هدفمندتر و دقیق‌تر شود. همانطور که حوزه پردازش زبان طبیعی به سرعت در حال پیشرفت است، ادغام تکنیک‌ها و معماری‌های نوظهور ممکن است امکانات جدیدی را برای بهبود خلاصه‌سازی متون بیومدیکال آزاد کند.

مراجع

- [1] Dalal, Vipul, and Latesh Malik. "A survey of extractive and abstractive text summarization techniques." 2013 6th Internab1. IEEE, 2013.
- [2] Bharathi Mohan G; Prasanna Kumar R; Elakkiya R; Siva Jyothi Natha Reddy B; Vemireddy Anvitha " Fine-Tuning Pretrained Transformers for Abstractive News Summarization" 2023 EASCT, IEEE
- [3] Hassan Shakil , Ahmad Farooq, Jugal Kalita. "Abstractive text summarization: State of the art, challenges, and improvements"
- [4] Tian Shi and Yaser Keneshloo and Naren Ramakrishnan and Chandan, K. Reddy: Neural Abstractive Text Summarization with Sequence-to-Sequence Models, arXiv: (2020)
- [5] K. Girthana; S. Swamynathan; A. R. Nirupama; S. Sri Akshya; S. Adhithyan, "Web-based Pretrained Transformer Model for Scientific Paper Summarization (WPT-SPS)"
- [6] T.Lin, Y. Wang, X. Liu,and X.Qiu, "A survey of transformers",AI Open,2022.